

# Assistente de Triagem Médica com IA: Um Sistema Baseado em Fine-Tuning de LLMs para Apoio Inicial ao Paciente

1<sup>st</sup> Bernardo Rohlfs

*Pontifícia Universidade Católica de Minas Gerais*  
Belo Horizonte, Brasil  
berohlfs@gmail.com

3<sup>rd</sup> Hitalo Silveira

*Pontifícia Universidade Católica de Minas Gerais*  
Belo Horizonte, Brasil  
hitalo.porto@sga.pucminas.br

5<sup>th</sup> Vitor Lion

*Pontifícia Universidade Católica de Minas Gerais*  
Belo Horizonte, Brasil  
vitor.lion@sga.pucminas.br

2<sup>nd</sup> Eric Jardim

*Pontifícia Universidade Católica de Minas Gerais*  
Belo Horizonte, Brasil  
eericjardim007@gmail.com

4<sup>th</sup> Pedro Motta

*Pontifícia Universidade Católica de Minas Gerais*  
Belo Horizonte, Brasil  
psmotta2001@hotmail.com

**Abstract**—Este artigo apresenta o desenvolvimento de um assistente virtual de triagem médica baseado em Inteligência Artificial. O objetivo do projeto é fornecer orientações iniciais a usuários que apresentam sintomas, ajudando na tomada de decisão sobre buscar atendimento médico. Utilizou-se uma base de dados com conversas médico-paciente e um modelo de linguagem treinado via fine-tuning para gerar respostas contextualizadas. Os resultados indicam que o sistema é capaz de distinguir sintomas leves de casos mais graves, oferecendo respostas seguras e adequadas. O trabalho demonstra o potencial de uso educacional de modelos de linguagem na saúde, especialmente como ferramenta de apoio informativo e preventivo.

## I. INTRODUÇÃO

Com o avanço da tecnologia e o fácil acesso à internet, tornou-se comum que pessoas busquem informações sobre saúde em mecanismos de busca e fóruns online ao perceberem sintomas. De acordo com o Centro de Controle e Prevenção de Doenças (CDC), 58,5% dos adultos nos Estados Unidos utilizaram a internet para procurar informações médicas nos 12 meses anteriores à pesquisa [1]. Além disso, uma pesquisa da YouGov revelou que 77% dos americanos afirmam que "sempre" ou "às vezes" pesquisam seus sintomas online antes de procurar ajuda médica profissional [2].

Apesar de ser uma prática popular, ela apresenta sérios riscos: a interpretação equivocada de sintomas pode levar à automedicação, atrasos na procura por atendimento médico adequado ou mesmo ao agravamento do quadro clínico.

Nesse cenário, surge a proposta de desenvolver uma ferramenta de apoio à triagem médica, que utilize os avanços da Inteligência Artificial (IA), mais especificamente os modelos de linguagem natural (LLMs), para simular o comportamento de um profissional da saúde em interações textuais com pacientes.

Essa ferramenta, apresentada neste artigo, tem como finalidade oferecer uma orientação inicial sobre os sintomas relatados pelo usuário, sugerindo medidas simples em casos leves ou recomendando atendimento presencial quando necessário.

Além de reduzir a sobrecarga nos sistemas de saúde, a aplicação de soluções com IA contribui para democratizar o acesso a informações confiáveis e personalizadas sobre saúde. Isso é especialmente relevante em regiões com menor disponibilidade de profissionais médicos ou com barreiras de acesso a serviços.

O projeto possui um caráter educacional e visa contribuir para o uso consciente da IA na saúde digital, respeitando os limites éticos e técnicos. A proposta explora o uso de técnicas de fine-tuning aplicadas a um modelo da OpenAI [3], treinado com dados reais e sintéticos de conversas médico-paciente. Ao integrar esse modelo com ferramentas de automação e uma interface web leve, foi possível construir um sistema funcional, testável online e acessível ao público.

## II. MÉTODO

A solução proposta foi desenvolvida a partir de uma base de dados inicial contendo cerca de 1.000 linhas de diálogos entre médicos e pacientes, extraída do dataset "Doctor-Patient Conversation Dataset" disponibilizado no Kaggle [4]. Para ampliar a diversidade de sintomas e cenários clínicos, a equipe utilizou o ChatGPT para gerar aproximadamente 9.000 interações sintéticas adicionais, totalizando 10.000 linhas de conversa estruturadas.

### A. Preparação dos Dados

Os dados originais passaram por um processo de limpeza e padronização para garantir consistência. As conversas foram organizadas no formato JSONL, contendo turnos de fala entre paciente e médico com linguagem natural e contextualizada. O conteúdo gerado com IA foi cuidadosamente revisado para manter coerência com situações reais de triagem médica.

### B. Treinamento do Modelo

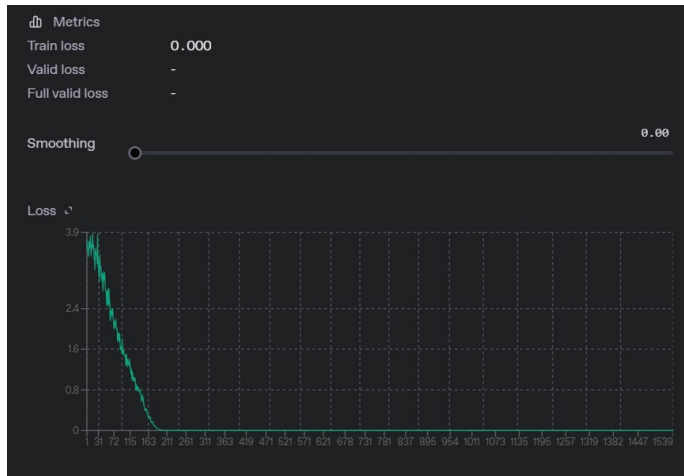


Fig. 1. Ilustração do Gráfico de perda (loss) do treinamento.




Fig. 2. Ilustração do Gráfico de acurácia (accuracy) do treinamento

Utilizou-se a API da OpenAI [3] para realizar o fine-tuning de um modelo da família GPT. Durante o processo de treinamento, o modelo apresentou rápida convergência, com a função de perda reduzida a quase zero em menos de 200 iterações, como mostra a Figura 2. A acurácia também se estabilizou acima de 95% nas etapas iniciais, atingindo 100% em diversas execuções, conforme ilustrado na Figura 3. Esses resultados indicam um bom ajuste aos dados sintéticos e reais utilizados na etapa de fine-tuning.

### C. Arquitetura do Sistema




Fig. 3. Ilustração da arquitetura que foi usada para o desenvolvimento do trabalho.

A arquitetura do sistema é composta por:

- n8n: ferramenta de automação que recebe a mensagem do usuário, processa e envia para a IA;
- OpenAI API: onde está hospedado o modelo treinado com fine-tuning;
- Interface Web (HTML, CSS, JavaScript): exibe a interface leve e responsiva para o usuário;
- GitHub Pages: usado como plataforma gratuita para hospedagem do frontend.

### D. Funcionamento do Sistema

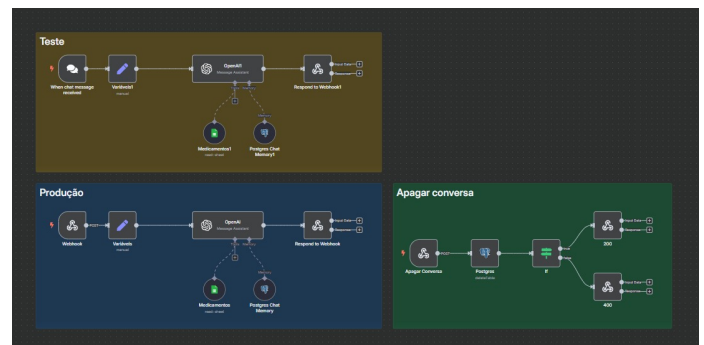


Fig. 4. Ilustração do fluxo usado para o funcionamento o sistema.

O funcionamento da aplicação começa quando o usuário digita sua dúvida sobre saúde. Essa mensagem é enviada para o backend por meio do n8n, que consulta o modelo de IA treinado e devolve uma resposta com base no contexto. Quando a dúvida é simples, o sistema usa uma base de dados interna para oferecer orientações básicas. Já nos casos mais sérios ou de risco, a resposta recomenda que a pessoa procure atendimento médico presencial.

### E. Parâmetros de Treinamento

O fine-tuning foi realizado sobre o modelo gpt-4o-mini-2024-07-18, escolhendo-se essa arquitetura pelo bom equilíbrio entre capacidade de compreensão contextual e custo computacional. O conjunto de treinamento somou 2 211 692 tokens distribuídos em quatro épocas. Cada atualização de gradientes utilizou lotes (batches) de 26 exemplos, e a taxa de aprendizado efetiva foi reduzida para 10% do valor padrão (multiplicador de learning rate igual a 0,1) a fim de mitigar oscilações e overfitting. Para garantir reprodutibilidade, definiu-se a semente pseudo-aleatória 1024, e três checkpoints foram salvos ao longo do processo, permitindo retomar versões intermediárias caso ajustes adicionais fossem necessários. Esses parâmetros produziram as curvas de perda e acurácia exibidas nas Figuras 2 e 3, confirmando a rápida convergência do modelo.

### III. RESULTADOS

O sistema foi testado online com um protótipo funcional. Os testes demonstraram que o modelo responde de forma fluida, coerente e dentro do escopo educacional proposto. Foi observada a capacidade do sistema de:

- Reconhecer sintomas comuns com boa precisão;
- Sugerir orientações seguras para sintomas leves;
- Recomendar a busca por atendimento médico quando apropriado.

Os testes foram realizados com inputs variados de sintomas, simulando conversas reais com pacientes. As respostas apresentaram consistência mesmo em cenários ambíguos, demonstrando que o modelo consegue manter o contexto da conversa e indicar medidas seguras. A integração com n8n demonstrou eficácia na orquestração do fluxo de comunicação e no encaminhamento das requisições.

Além da avaliação geral, foram realizados testes com entradas específicas. A Tabela I apresenta exemplos de interações simuladas com o assistente de triagem:

TABLE I  
EXEMPLOS DE INTERAÇÕES COM O CHATBOT

| Sintoma informado                       | Resposta gerada pelo modelo                               | Classificação |
|---|---|---------------|
| Estou com dor de cabeça e cansaço.      | Pode ser algo leve. Tente descansar e se hidratar.        | Leve          |
| Meu filho está com febre alta e vômito. | Recomendo que você procure um pronto atendimento médico.  | Grave         |
| Minha garganta está arranhando.         | Pode ser irritação leve. Observe por 48h e beba líquidos. | Leve/Moderado |

### IV. CONCLUSÕES

O projeto mostrou que é possível usar inteligência artificial para ajudar na triagem inicial de sintomas de forma segura e educativa. Mesmo com limitações — como não poder substituir um profissional de saúde —, o sistema conseguiu orientar os usuários de maneira eficiente. Para o futuro, estão previstas melhorias como o uso de tokens de sessão para

garantir mais segurança, aumento da base de dados e melhorias na interface.

A combinação de tecnologias atuais, como modelos de linguagem (LLMs) e ferramentas de automação, abre novas possibilidades para apoiar a saúde pública. Durante o projeto, foi possível aprender na prática sobre ajuste fino de LLMs, uso de APIs e desenvolvimento web, mostrando como essas tecnologias podem contribuir na área da saúde digital.

Do ponto de vista ético, é essencial que ferramentas como essa sejam usadas com clareza, sem prometer diagnósticos, e que os usuários entendam suas limitações. O uso responsável da IA na saúde pode ajudar a levar informações confiáveis a mais pessoas, mas sempre com supervisão e validação de profissionais da área. Por isso, o projeto serve como um ponto de partida promissor para novas iniciativas que unam tecnologia, responsabilidade social e inovação no cuidado básico à saúde.

É crucial ressaltar que o assistente atua apenas como apoio educacional, seguindo protocolos rígidos para jamais substituir avaliação médica presencial. Todas as interações são projetadas para priorizar segurança, encaminhando casos complexos a profissionais humanos.

### REFERÊNCIAS

#### REFERENCES

- [1] Centers for Disease Control and Prevention, "Products - Data Briefs - Number 482 - October 2023," Oct. 2023. [Online]. Available: <https://www.cdc.gov/nchs/products/databriefs/db482.htm>
- [2] YouGov, "Most Americans search online for health information before going to the doctor," YouGovAmerica, Feb. 2022. [Online]. Available: <https://today.yougov.com/topics/health/articles-reports/2022/02/16/most-americans-search-health-info-online>
- [3] OpenAI, "Fine-tuning models," OpenAI Documentation. [Online]. Available: <https://platform.openai.com/docs/guides/fine-tuning>
- [4] Kaggle, "Doctor-Patient Conversation Dataset," [Online]. Available: <https://www.kaggle.com/datasets/tboyle10/doctor-patient-conversations>